

Mon Projet Data Science

Projet Fil Rouge Data Science - Sujet Libre

Étudiante 1 : Monica RADIFERA RASAMOELI-
JAONA

Étudiant 2 : Hocine AKLI

2026-05-19

Table of contents

1	Introduction et Contexte Métier	2
1.1	Contexte du Projet	3
1.2	Objectif Analytique	3
2	Acquisition et Préparation des Données (Data Wrangling)	3
2.1	Audit de Qualité	3
3	 Jalon 1 : Data Wrangling & Nettoyage (Squelette Étudiant)	4
3.0.a	1. Importation des packages et chargement des données	4
3.0.b	2. Audit initial des données	4
3.0.c	3. Nettoyage des colonnes inutile	4
3.0.d	4. Renommage des colonnes	4
3.0.e	5. Nettoyage de la date	4
3.0.f	6. Suppression des agrégats non-pays	4
3.0.g	7. Suppression des colonnes redondantes	4
3.0.h	8. Gestion des valeurs manquantes	4
3.0.i	9. tri, suppression des doublons et validation finale	5
3.0.j	10. Sauvegarde des données propres	5
4	Analyse Exploratoire des Données (EDA)	5
4.1	Statistiques Descriptives	5
4.2	Statistiques Descriptives	5
4.3	Ingénierie de Variables (Feature Engineering)	5
5	 Jalon 1 : Analyse Exploratoire des Données (EDA) & Visualisation (Squelette Étudiant) ..	6
5.0.a	1. Importation des packages et configuration du style	6
5.0.b	2. Ingénierie de variables temporelles	6
5.0.c	3. Visualisations Professionnelles	6
5.0.d	4. Synthèse des observations clés	6
6	Visualisation Multidimensionnelle (Insights)	7
6.1	Profils et Distributions Caractéristiques	7
6.2	Corrélations Globales	7

7	Modélisation et Apprentissage	7
7.1	Schéma Global du Pipeline de Données	7
7.2	Modélisation Tabulaire (Machine Learning)	8
7.2.a	Travaux Pratiques de Modélisation Tabulaire	8
8	🧠 Jalon 2 : Modélisation Prédictive & Apprentissage (Squelette Étudiant)	8
8.0.a	1. Préparation de l'environnement	8
8.0.b	2. Définition des variables et split chronologique	8
8.0.c	3. Entraînement du modèle de Forêt Aléatoire	8
8.0.d	4. Évaluation métrique	8
8.0.e	5. Importance des variables explicatives	8
8.1	Modélisation Vision / Deep Learning (Analyse d'Images ou Signaux)	8
8.1.a	Travaux Pratiques de Vision par Ordinateur (CNN)	9
9	📷 Jalon 2 : Brique de Vision par Ordinateur (CNN & TensorFlow) (Squelette Étudiant)	9
9.0.a	1. Préparation de l'environnement	9
9.0.b	2. Génération du jeu d'images synthétiques	9
9.0.c	3. Split d'évaluation (Entraînement / Validation)	9
9.0.d	4. Conception de l'architecture du CNN	9
9.0.e	5. Compilation et Entraînement	9
10	Évaluation Métrique et Validation	9
10.1	Stratégie de Validation	9
10.2	Résultats et Interprétation	10
11	Data Storytelling et Communication	10
11.1	Recommandations Stratégiques / Métier	10
11.2	Limites et Perspectives	10
	Bibliographie	10
	Bibliography	10

1 Introduction et Contexte Métier



Figure 1: CI Compilation Pipeline

Ce projet analyse les données sur le Mpox (Monkeypox) pour mieux comprendre la propagation du virus. Face à l'émergence de cette maladie dans plusieurs pays, il est important de pouvoir suivre l'évolution des cas et identifier les zones à risque.

La problématique est de savoir comment prédire et anticiper la propagation du Mpox à partir de données réelles. Cela pose des questions scientifiques sur les tendances temporelles, les différences entre pays et les facteurs influençant la diffusion du virus.

L'objectif est d'offrir des insights utiles pour la prise de décision en santé publique : où surveiller davantage, quand anticiper un pic, et comment optimiser les moyens de prévention.

1.1 Contexte du Projet

Ce projet étudie la propagation du Mpox dans le but de détecter des tendances et des zones à risque. Le domaine d'étude est la santé publique, avec un focus sur l'épidémiologie et l'analyse de données temporelles.

Ce sujet est stratégique car le Mpox représente une menace sanitaire émergente, et sa surveillance permet de mieux préparer les systèmes de santé. Comprendre sa dynamique aide à prévenir de futures vagues de contamination.

L'analyse quantitative est indispensable car elle transforme des données brutes en indicateurs actionnables. Elle permet de mesurer objectivement l'évolution des cas, de comparer les pays et de fonder les décisions sur des faits plutôt que sur des intuitions.

1.2 Objectif Analytique

Les variables cibles principales sont la date, le pays, les new cases et new deaths (nouveaux cas et décès quotidiens), ainsi que les total cases et total deaths (cas et décès cumulés). L'objectif est d'analyser l'évolution de ces indicateurs dans le temps et d'identifier les pays les plus touchés par le Mpox.

Ce dataset est tabulaire avec des données épidémiologiques quotidiennes par pays sur une période d'un an. L'analyse se concentre sur ces 15 variables disponibles pour comprendre la dynamique de propagation du virus sans ajouter de données externes.

2 Acquisition et Préparation des Données (Data Wrangling)

Le succès de tout projet de Data Science repose sur la qualité de la préparation des données [1]. Cette section documente l'audit de qualité et les étapes de nettoyage appliquées à vos jeux de données bruts.

2.1 Audit de Qualité

Le fichier de données a été vérifié sur les aspects essentiels de qualité, notamment la structure des colonnes, la présence de valeurs manquantes et la présence éventuelle de doublons. L'audit a montré que certaines colonnes contenaient trop de cases vides, ce qui risquait de nuire à la fiabilité des analyses.

Nous avons donc choisi de supprimer ces colonnes afin de conserver uniquement les variables réellement exploitables. En parallèle, les doublons ont aussi été contrôlés pour éviter les répétitions dans le jeu de données et garantir une base plus propre.

Après ce tri, les données restantes ont pu être analysées sans difficulté majeure. Le dataset final est donc mieux adapté aux étapes d'exploration, de visualisation et de modélisation. ## Algorithme de Nettoyage Le traitement des données a commencé par un nettoyage des dates afin d'obtenir un format homogène et exploitable pour l'analyse temporelle. Nous avons ensuite supprimé les colonnes contenant trop de valeurs manquantes, car elles apportaient peu d'information et risquaient de fragiliser les analyses.

Comme le jeu de données contenait à la fois des informations au niveau des pays et des continents, nous avons conservé uniquement les données par pays afin d'avoir une analyse plus précise et plus cohérente.

Enfin, nous avons supprimé les colonnes jugées non utiles car redondantes, afin de simplifier le jeu de données et de garder uniquement les variables pertinentes pour l'analyse. Nous avons également recalculé les valeurs totales death pour les valeurs manquantes, afin de garantir la cohérence des données avant l'analyse. Les données sont ensuite triées par pays et date afin d'avoir une meilleure visibilité. Ces étapes ont permis de travailler sur une base plus propre, plus homogène et mieux adaptée aux analyses et à la modélisation. ## Travaux Pratiques de Wrangling

3 Jalon 1 : Data Wrangling & Nettoyage (Squelette Étudiant)

Ce notebook correspond à la première étape du **Jalon 1**. L'objectif est d'importer le jeu de données brut (`data/raw/raw_data_sample.csv`), d'effectuer un audit de sa qualité (données manquantes, anomalies physiques, formats de dates hétérogènes) et de le nettoyer à l'aide de votre package personnalisé `src.data_clean`.

3.0.a 1. Importation des packages et chargement des données

3.0.b 2. Audit initial des données

À faire par l'étudiant : Explorez le dataset brut pour évaluer sa structure : - Quelles sont les dimensions du dataset ? - Quels sont les types de données par colonne ? - Reste-t-il des valeurs nulles ? Quel est le taux de valeurs manquantes par variable ? - Y a-t-il des doublons ?

3.0.c 3. Nettoyage des colonnes inutile

3.0.d 4. Renommage des colonnes

3.0.e 5. Nettoyage de la date

La colonne `date` a été convertie au format `datetime` afin de permettre des analyses temporelles : évolution des cas, agrégation par mois, suivi de la progression de l'épidémie.

3.0.f 6. Suppression des agrégats non-pays

Les lignes correspondant aux continents ou aux agrégats globaux ont été supprimées afin de conserver uniquement les observations par pays.

3.0.g 7. Suppression des colonnes redondantes

3.0.h 8. Gestion des valeurs manquantes

Les valeurs manquantes des colonnes numériques principales ont été imputées par la médiane. Ce choix permet de limiter l'influence des valeurs extrêmes, fréquentes dans les données épidémiologiques où certains pays peuvent concentrer un nombre de cas beaucoup plus élevé que d'autres.

3.0.i 9. tri, suppression des doublons et validation finale

3.0.j 10. Sauvegarde des données propres

Pour ce projet, le travail de data wrangling comprend :

- chargement du CSV brut ;
 - audit initial du dataset : dimensions, types, valeurs manquantes et doublons ;
 - conversion de la colonne date au format datetime ;
 - suppression des agrégats globaux et continentaux ;
 - renommage des colonnes principales ;
 - traitement des valeurs manquantes par imputation ;
 - suppression des colonnes redondantes ou peu utiles pour l'analyse ;
 - vérification et suppression des doublons ;
 - tri des données par pays et par date ;
 - sauvegarde du dataset nettoyé pour l'analyse exploratoire.
-

4 Analyse Exploratoire des Données (EDA)

Dans cette section, nous analysons les relations statistiques fondamentales qui régissent votre domaine d'étude au sein du jeu de données.

4.1 Statistiques Descriptives

4.2 Statistiques Descriptives

Le jeu de données nettoyé contient les variables principales liées au suivi du Mpox, notamment le pays, la date, le nombre total de cas, le nombre total de décès, les nouveaux cas quotidiens et les nouveaux décès quotidiens. Les premières observations montrent une structure temporelle cohérente, avec des valeurs numériques qui varient selon les pays.

Les variables cumulées comme `total_cases` et `total_deaths` permettent de suivre l'évolution globale de l'épidémie, tandis que les variables journalières `daily_new_cases` et `daily_new_deaths` mettent en évidence les fluctuations d'un jour à l'autre. On observe aussi que, dans certains pays, les décès restent nuls sur plusieurs périodes, ce qui traduit une faible mortalité observée dans ces données.

Dans l'ensemble, les variables nettoyées sont bien adaptées à une analyse descriptive, car elles permettent de comparer les pays, d'étudier l'évolution dans le temps et d'identifier les zones où la propagation est la plus marquée.

4.3 Ingénierie de Variables (Feature Engineering)

Dans notre cas, l'ingénierie de variables est restée assez limitée, car le dataset contient déjà les informations utiles pour suivre l'évolution du Mpox. Nous avons donc conservé les variables principales comme le pays, la date, les nouveaux cas, les nouveaux décès, les cas totaux et les décès totaux. Quand certaines valeurs de `total_deaths` étaient manquantes, nous les avons recalculées à partir des informations disponibles afin de garder une variable exploitable et cohérente.

L'intérêt de cette étape est de s'assurer que les données utilisées pour la suite du projet soient fiables et complètes. Cela permet aussi de garder une base propre pour l'analyse descriptive et la modélisation, sans ajouter de variables artificielles qui ne viennent pas du dataset. En pratique, cela montre une démarche rigoureuse de préparation des données, ce qui est important dans un projet de data science. Cette étape a surtout servi à nettoyer, compléter et organiser les variables déjà présentes, plutôt qu'à créer de nouvelles caractéristiques. C'est une approche adaptée à un rapport étudiant, parce qu'elle reste fidèle aux données réelles et au travail effectivement réalisé.

Travaux Pratiques d'Exploration Visuelle (EDA)

5 Jalon 1 : Analyse Exploratoire des Données (EDA) & Visualisation (Squelette Étudiant)

Ce notebook est dédié à la découverte de relations clés et à l'analyse visuelle de nos données. À partir du jeu de données propre généré précédemment, nous allons enrichir nos variables explicatives et appeler les fonctions de notre module de visualisation `src.utils_viz` pour générer des graphiques professionnels.

5.0.a 1. Importation des packages et configuration du style

5.0.b 2. Ingénierie de variables temporelles

À faire par l'étudiant : Appliquez la fonction `feature_engineering` de `src.data_clean` pour enrichir votre DataFrame en caractéristiques de temps classiques (heures, jours de la semaine).

5.0.c 3. Visualisations Professionnelles

5.0.c.a A. Profils d'évolution et tendances

À faire par l'étudiant : Appliquez la fonction `plot_generic_trends` de votre module `src.utils_viz` pour tracer l'évolution de la valeur par rapport au temps.

5.0.c.b B. Matrice de corrélation multi-variables

À faire par l'étudiant : Appliquez la fonction `plot_correlation_matrix` de votre module `src.utils_viz` pour calculer et afficher graphiquement la carte thermique des corrélations sur les colonnes `['value', 'hour', 'dayofweek']`.

5.0.c.c C. Nuage de points bivarié

À faire par l'étudiant : Générez un nuage de points de la relation heure vs valeur en colorant les points selon la variable `dayofweek`, en utilisant votre fonction `plot_bivariate_scatter`.

5.0.d 4. Synthèse des observations clés

Sur la base de vos figures, listez les **insights majeurs** observés sur le comportement de vos variables.

6 Visualisation Multidimensionnelle (Insights)

Nous présentons ici les résultats visuels clés permettant de dégager des insights exploitables pour les décideurs, en s'appuyant sur notre module `src/utils_viz.py`.

À rédiger par les étudiants : Présentez et commentez en détail vos 3 à 5 insights majeurs découverts lors de l'exploration descriptive visuelle. Intégrez et justifiez les figures clés générées.

6.1 Profils et Distributions Caractéristiques

```
#| label: fig-distribution-density
#| fig-cap: "Distribution ou profils caractéristiques de vos variables clés."
#| echo: false
# TODO: Utiliser vos fonctions personnalisées de votre module pour tracer la
figure
```

[Commenter la figure et décrire vos observations ici]

6.2 Corrélations Globales

```
#| label: fig-correlation
#| fig-cap: "Matrice de corrélation de Spearman ou de Pearson entre variables."
#| echo: false
# TODO: Utiliser uv.plot_correlation_matrix() de votre module pour tracer la
figure
```

[Commenter la figure et décrire vos observations ici]

7 Modélisation et Apprentissage

7.1 Schéma Global du Pipeline de Données

Le pipeline complet intègre à la fois la branche analytique tabulaire (Machine Learning) et la branche d'analyse visuelle ou de signaux complexes (Deep Learning CNN) :

```
graph TD
    A[Données Brutes Multi-Sources CSV/API] -->|Formatage & Alignement| B(data_clean.clean_dates)
    C[Données Externes Complémentaires] -->|Imputation & Interpolation| D(data_clean.impute_missing_values)
    B & D -->|Gestion Outliers| E[Jeu de données Propre & Fusionné]
    E -->|Extraction Temporelle/Caractéristiques| F[Feature Engineering]
    F -->|Splits Temporels ou Stratifiés| G[Modèle Machine Learning Tabulaire]
    H[Flux Multimédias Réels Images/Signaux] -->|Prétraitement d'images/signaux| I[Réseau Convolutif CNN TensorFlow]
    G -->|Prédictions de la Problématique Métier| J[Livrables & Aide à la Décision]
```

```
I -->|Détection de Motifs Complexes| J
```

```
style E fill:#e0f2fe,stroke:#0284c7,stroke-width:2px
style J fill:#f0fdf4,stroke:#16a34a,stroke-width:2px
style G fill:#fef3c7,stroke:#d97706,stroke-width:2px
style I fill:#fef3c7,stroke:#d97706,stroke-width:2px
```

7.2 Modélisation Tabulaire (Machine Learning)

À rédiger par les étudiants : Expliquez le choix de vos algorithmes d'apprentissage (supervisé ou non supervisé) et décrivez l'importance des variables explicatives.

[Détaillez votre modélisation ici]

7.2.a Travaux Pratiques de Modélisation Tabulaire

8 Jalon 2 : Modélisation Prédicative & Apprentissage (Squelette Étudiant)

Dans ce notebook du **Jalon 2**, l'objectif est d'implémenter un pipeline complet d'apprentissage supervisé pour prédire une variable cible (*value*) à l'aide de Scikit-Learn.

Vous devrez mettre en œuvre une stratégie de découpage train/test chronologique pour respecter la causalité temporelle.

8.0.a 1. Préparation de l'environnement

8.0.b 2. Définition des variables et split chronologique

À faire par l'étudiant : - Identifiez vos colonnes prédictives (*features*) et la colonne cible (*value*). - Séparez chronologiquement vos données en ensembles d'entraînement (*Train*) et de test (*Test*). N'utilisez pas de split aléatoire !

8.0.c 3. Entraînement du modèle de Forêt Aléatoire

À faire par l'étudiant : - Instanciez et entraînez un modèle `RandomForestRegressor`. - Générez les prédictions *y_pred* sur l'ensemble de test.

8.0.d 4. Évaluation métrique

À faire par l'étudiant : Calculez et affichez les scores d'évaluation requis : - **MAE** (Mean Absolute Error) - **RMSE** (Root Mean Squared Error) - **R²** (Coefficient de détermination)

8.0.e 5. Importance des variables explicatives

À faire par l'étudiant : Extrayez et affichez l'importance relative de chaque caractéristique prédictive.

8.1 Modélisation Vision / Deep Learning (Analyse d'Images ou Signaux)

À rédiger par les étudiants : Expliquez l'intérêt de la brique de Deep Learning (images, signaux ou traitement de données structurées complexes) pour classifier ou enrichir vos prédictions. Détaillez

l'architecture de votre réseau de neurones convolutif (CNN) conçu sous TensorFlow/Keras (conv, pooling, dense, dropout, activation) et commentez les courbes d'apprentissage obtenues.

[Détaillez votre architecture CNN et analysez ici]

8.1.a Travaux Pratiques de Vision par Ordinateur (CNN)

9 Jalon 2 : Brique de Vision par Ordinateur (CNN & TensorFlow) (Squelette Étudiant)

Ce notebook est dédié à la brique d'analyse d'images du **Jalon 2**. L'objectif est de concevoir un Réseau de Neurones Convolutif (CNN) sous TensorFlow/Keras pour classer des motifs géométriques simples (Classe 0: Cercle vs Classe 1: Multiples Rectangles).

9.0.a 1. Préparation de l'environnement

9.0.b 2. Génération du jeu d'images synthétiques

Pour travailler de manière autonome sans importer de lourdes bases d'images externes, cette fonction utilitaire génère des images simulées en 64×64 pixels de formes simples (Cercle vs Rectangles).

9.0.c 3. Split d'évaluation (Entraînement / Validation)

À faire par l'étudiant : Divisez vos données d'images `X_images` et `y_labels` en 80% pour l'entraînement et 20% pour la validation.

9.0.d 4. Conception de l'architecture du CNN

À faire par l'étudiant : Instanciez un réseau convolutif séquentiel Keras comprenant des couches `Conv2D`, `MaxPooling2D`, `Flatten`, `Dense` et un `Dropout` pour classer nos deux formes géométriques.

9.0.e 5. Compilation et Entraînement

À faire par l'étudiant : - Compilez le modèle avec l'optimiseur '`adam`' et la fonction de perte binaire. - Entraînez votre CNN sur environ 5 époques.

10 Évaluation Métrique et Validation

10.1 Stratégie de Validation

À rédiger par les étudiants : Expliquez pourquoi le découpage d'évaluation choisi (ex: validation temporelle, stratifiée ou par groupe) est adapté à la structure de vos données pour éviter les fuites de données.

[Rédiger la section de validation ici]

10.2 Résultats et Interprétation

À rédiger par les étudiants : Complétez le tableau d'évaluation ci-dessous en reportant vos résultats de modélisation.

Modèle	Métrique 1 (ex: MAE / Précision)	Métrique 2 (ex: RMSE / F1-Score)	R ² / Score (%)
Baseline (ex: Naïve / Moyenne)	[À compléter]	[À compléter]	[À compléter]
Modèle Choisi	[À compléter]	[À compléter]	[À compléter]

[Interpréter et comparer les métriques d'erreur calculées ici]

11 Data Storytelling et Communication

11.1 Recommandations Stratégiques / Métier

À rédiger par les étudiants : Formulez des recommandations stratégiques, opérationnelles et innovantes basées sur vos découvertes analytiques et prédictives pour guider les décideurs.

[Rédiger vos recommandations ici]

11.2 Limites et Perspectives

À rédiger par les étudiants : Identifiez honnêtement les biais ou limites de votre approche et proposez des pistes d'amélioration futures (ex: intégration de données externes réelles, modélisation plus poussée).

[Rédiger les limites et perspectives ici]

Ce document dynamique a été compilé en Quarto [2].

Bibliographie

Bibliography

- [1] W. McKinney, *Python for Data Analysis: Data Wrangling with Pandas, NumPy, and IPython*. O'Reilly Media, 2020.
- [2] Q. D. Team, "Quarto Dynamic Publishing System: Collaborative Scientific and Technical Publishing." Accessed: May 18, 2026. [Online]. Available: <https://quarto.org/>