

Mon Projet Data Science

Projet Fil Rouge Data Science - Sujet Libre

Étudiante 1 : Monica RADIFERA RASAMOELI-
JAONA

Étudiant 2 : Hocine AKLI

2026-05-20

Table of contents

1	Introduction et Contexte Métier	2
1.1	Contexte du Projet	2
1.2	Objectif Analytique	2
2	Acquisition et Préparation des Données (Data Wrangling)	3
2.1	Audit de Qualité	3
3	 Jalon 1 : Data Wrangling & Nettoyage (Squelette Étudiant)	3
3.0.a	1. Importation des packages et chargement des données	3
3.0.b	2. Audit initial des données	4
3.0.c	3. Nettoyage des colonnes inutile	6
3.0.d	4. Renommage des colonnes	6
3.0.e	5. Nettoyage de la date	6
3.0.f	6. Suppression des agrégats non-pays	7
3.0.g	7. Suppression des colonnes redondantes	7
3.0.h	8. Gestion des valeurs manquantes	7
3.0.i	9. tri, suppression des doublons et validation finale	8
3.0.j	10. Sauvegarde des données propres	8
4	Analyse Exploratoire des Données (EDA)	9
4.1	Statistiques Descriptives	9
4.2	Ingénierie de Variables (Feature Engineering)	9
5	 Jalon 1 : Analyse Exploratoire des Données (EDA) & Visualisation (Squelette Étudiant) .	10
5.0.a	1. Importation des packages et configuration du style	10
5.0.b	2. Ingénierie de variables temporelles	10
5.0.c	3. Visualisations Professionnelles	11
5.0.d	4. Synthèse des observations clés	11
6	Visualisation Multidimensionnelle (Insights)	12
7	Modélisation et Apprentissage	14
7.1	Schéma Global du Pipeline de Données	14
7.2	Modélisation Tabulaire (Machine Learning)	15

7.2.a Travaux Pratiques de Modélisation Tabulaire	15
7.3 Modélisation Vision / Deep Learning (Analyse d'Images ou Signaux)	15
7.3.a Travaux Pratiques de Vision par Ordinateur (CNN)	15
8 Évaluation Métrique et Validation	15
8.1 Stratégie de Validation	15
8.2 Résultats et Interprétation	15
9 Data Storytelling et Communication	16
9.1 Recommandations Stratégiques / Métier	16
9.2 Limites et Perspectives	16
Bibliographie	16
Bibliography	16

1 Introduction et Contexte Métier



Figure 1: CI Compilation Pipeline

Ce projet analyse les données sur le Mpox (Monkeypox) pour mieux comprendre la propagation du virus. Face à l'émergence de cette maladie dans plusieurs pays, il est important de pouvoir suivre l'évolution des cas et identifier les zones à risque.

La problématique est de savoir comment prédire et anticiper la propagation du Mpox à partir de données réelles. Cela pose des questions scientifiques sur les tendances temporelles, les différences entre pays et les facteurs influençant la diffusion du virus.

L'objectif est d'offrir des insights utiles pour la prise de décision en santé publique : où surveiller davantage, quand anticiper un pic, et comment optimiser les moyens de prévention.

1.1 Contexte du Projet

Ce projet étudie la propagation du Mpox dans le but de détecter des tendances et des zones à risque. Le domaine d'étude est la santé publique, avec un focus sur l'épidémiologie et l'analyse de données temporelles.

Ce sujet est stratégique car le Mpox représente une menace sanitaire émergente, et sa surveillance permet de mieux préparer les systèmes de santé. Comprendre sa dynamique aide à prévenir de futures vagues de contamination.

L'analyse quantitative est indispensable car elle transforme des données brutes en indicateurs actionnables. Elle permet de mesurer objectivement l'évolution des cas, de comparer les pays et de fonder les décisions sur des faits plutôt que sur des intuitions.

1.2 Objectif Analytique

Les variables cibles principales sont la date, le pays, les new cases et new deaths (nouveaux cas et décès quotidiens), ainsi que les total cases et total deaths (cas et décès cumulés). L'objectif est d'analyser l'évolution de ces indicateurs dans le temps et d'identifier les pays les plus touchés par le Mpox.

Ce dataset est tabulaire avec des données épidémiologiques quotidiennes par pays sur une période d'un an. L'analyse se concentre sur les variables principales conservées après nettoyage

2 Acquisition et Préparation des Données (Data Wrangling)

Le succès de tout projet de Data Science repose sur la qualité de la préparation des données [1]. Cette section documente l'audit de qualité et les étapes de nettoyage appliquées à vos jeux de données bruts.

2.1 Audit de Qualité

Le fichier de données a été vérifié sur les aspects essentiels de qualité, notamment la structure des colonnes, la présence de valeurs manquantes et la présence éventuelle de doublons. L'audit a montré que certaines colonnes contenaient trop de cases vides, ce qui risquait de nuire à la fiabilité des analyses.

Nous avons donc choisi de supprimer ces colonnes afin de conserver uniquement les variables réellement exploitables. En parallèle, les doublons ont aussi été contrôlés pour éviter les répétitions dans le jeu de données et garantir une base plus propre.

Après ce tri, les données restantes ont pu être analysées sans difficulté majeure. Le dataset final est donc mieux adapté aux étapes d'exploration, de visualisation et de modélisation. ## Algorithme de Nettoyage Le traitement des données a commencé par un nettoyage des dates afin d'obtenir un format homogène et exploitable pour l'analyse temporelle. Nous avons ensuite supprimé les colonnes contenant trop de valeurs manquantes, car elles apportaient peu d'information et risquaient de fragiliser les analyses.

Comme le jeu de données contenait à la fois des informations au niveau des pays et des continents, nous avons conservé uniquement les données par pays afin d'avoir une analyse plus précise et plus cohérente.

Enfin, nous avons supprimé les colonnes jugées non utiles car redondantes, afin de simplifier le jeu de données et de garder uniquement les variables pertinentes pour l'analyse. Nous avons également traité les valeurs manquantes de la variable `total_deaths` à l'aide d'une imputation adaptée, afin de garantir la cohérence du dataset avant l'analyse. ## Travaux Pratiques de Wrangling

3 Jalon 1 : Data Wrangling & Nettoyage (Squelette Étudiant)

Ce notebook correspond à la première étape du **Jalon 1**. L'objectif est d'importer le jeu de données brut et d'effectuer un audit de sa qualité (données manquantes, anomalies physiques, formats de dates hétérogènes) et de le nettoyer à l'aide de votre package personnalisé `src.data_clean`.

3.0.a 1. Importation des packages et chargement des données

```
Libraries importées avec succès ! Prêt à démarrer le Wrangling.
```

	iso_code	location	date	total_cases	total_deaths	new_cases	new_deaths	new_cases_smoothed	new_deaths_smoothed	new_cases_per_million	new_deaths_per_million	total_cases_per_million	total_deaths_per_million
0	Africa	OWID_2020-05-01	2.0	0.0	0.0	0.29	NaN	NaN	NaN	NaN	NaN	0.00140.0	0.00140.0
1	Africa	OWID_2020-05-02	2.0	0.0	0.0	0.29	NaN	NaN	0.019	NaN	0.0	0.00140.0	0.00140.0
2	Africa	OWID_2020-05-03	2.0	0.0	0.0	0.29	0.0	NaN	NaN	0.0	NaN	0.00140.0	0.00140.0
3	Africa	OWID_2020-05-04	2.0	0.0	0.0	0.29	NaN	0.0	0.019	NaN	0.0	0.00140.0	0.00140.0
4	Africa	OWID_2020-05-05	2.0	0.0	0.0	0.29	NaN	0.0	NaN	NaN	NaN	0.00140.0	0.00140.0

3.0.b 2. Audit initial des données

Explorez le dataset brut pour évaluer sa structure : - Quelles sont les dimensions du dataset ? - Quels sont les types de données par colonne ? - Reste-t-il des valeurs nulles ? Quel est le taux de valeurs manquantes par variable ? - Y a-t-il des doublons ?

```
Dimensions : (33669, 15)
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 33669 entries, 0 to 33668
Data columns (total 15 columns):
#   Column                                Non-Null Count  Dtype
---  -
0   location                              33669 non-null  object
1   iso_code                              33669 non-null  object
2   date                                  33669 non-null  object
3   total_cases                           33669 non-null  float64
4   total_deaths                          33663 non-null  float64
5   new_cases                             33663 non-null  float64
6   new_deaths                            33666 non-null  float64
7   new_cases_smoothed                    33669 non-null  float64
8   new_deaths_smoothed                   13391 non-null  float64
9   new_cases_per_million                  13494 non-null  float64
10  total_cases_per_million                 13484 non-null  float64
11  new_cases_smoothed_per_million          13408 non-null  float64
12  new_deaths_per_million                  13606 non-null  float64
13  total_deaths_per_million                33669 non-null  float64
14  new_deaths_smoothed_per_million         33669 non-null  float64
dtypes: float64(12), object(3)
memory usage: 3.9+ MB
```

Valeurs manquantes par colonne :

```

location          0
iso_code          0
date              0
total_cases       0
total_deaths      6
new_cases         6
new_deaths        3
new_cases_smoothed 0
new_deaths_smoothed 20278
new_cases_per_million 20175
total_cases_per_million 20185
new_cases_smoothed_per_million 20261
new_deaths_per_million 20063
total_deaths_per_million 0
new_deaths_smoothed_per_million 0
dtype: int64

```

Taux de valeurs manquantes (%) :

```

new_deaths_smoothed      60.227509
new_cases_smoothed_per_million 60.177017
total_cases_per_million  59.951291
new_cases_per_million    59.921590
new_deaths_per_million   59.588939
new_cases                0.017821
total_deaths             0.017821
new_deaths               0.008910
location                 0.000000
iso_code                 0.000000
date                    0.000000
total_cases              0.000000
new_cases_smoothed       0.000000
total_deaths_per_million 0.000000
new_deaths_smoothed_per_million 0.000000
dtype: float64

```

Nombre de doublons : 3

	total_cases	total_deaths	new_cases	new_deaths	new_cases_smoothed	new_deaths_smoothed	total_cases_per_million	total_deaths_per_million	new_cases_per_million	new_deaths_per_million	new_cases_smoothed_per_million	new_deaths_smoothed_per_million
count	33669.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000

	total	total_deaths	new_cases	cases_per_100k	deaths_per_100k	tests_per_100k	cases_million	deaths_million	tests_billion	cases_billion	deaths_billion	tests_trillion
mean	1938.812796	19877.784420	0.012297	780489.012498	0.085680	9.413280	0.072730	0.000068	0.011200	0.000080		
std	8458.948848	83303.688801	0.167039	287408.89431	0.046113	0.643406	0.139600	0.002010	0.041830	0.000991		
min	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000
25%	4.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.688500	0.000000	0.000000	0.000000	0.000000
50%	21.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.878000	0.000000	0.000000	0.000000	0.000000
75%	257.000000	0.000000	0.000000	0.000000	0.570000	0.000000	0.000000	0.818000	0.024000	0.000000	0.000000	0.000000
max	87376.000000	0.000000	0.020000	0.000000	0.891400	0.000000	0.821200	0.836150	0.043000	0.111000	0.587380	0.031760

3.0.c 3. Nettoyage des colonnes inutile

Supression de la colonne iso_code

	location	total	total_deaths	new_cases	new_deaths	total_tests	total_hospitalizations	total_icu	total_ventilators	total_ventilators	total_ventilators	total_ventilators	million	
0	Africa	2022-03-27	700	2.0	0.0	0.0	0.29	NaN	NaN	NaN	NaN	NaN	0.0014	0.0
1	Africa	2022-03-27	702	2.0	0.0	0.0	0.29	NaN	NaN	0.019	NaN	0.0	0.0014	0.0
2	Africa	2022-03-27	703	2.0	0.0	0.0	0.29	0.0	NaN	NaN	0.0	NaN	0.0014	0.0
3	Africa	2022-03-27	704	2.0	0.0	0.0	0.29	NaN	0.0	0.019	NaN	0.0	0.0014	0.0
4	Africa	2022-03-27	705	2.0	0.0	0.0	0.29	NaN	0.0	NaN	NaN	NaN	0.0014	0.0

3.0.d 4. Renommage des colonnes

Renommage des colonnes cibles pour une analyse exploitable

	country	total	total_density	women_served	sdg-target	share	pharmaceuticals	npld-drug	pilipin	mild-m	million		
0	Africa	2700	2.0	0.0	0.0	0.29	NaN	NaN	NaN	NaN	0.0014	0.0	
1	Africa	2700	2.0	0.0	0.0	0.29	NaN	NaN	0.019	NaN	0.0	0.0014	0.0
2	Africa	2700	2.0	0.0	0.0	0.29	0.0	NaN	NaN	0.0	NaN	0.0014	0.0
3	Africa	2700	2.0	0.0	0.0	0.29	NaN	0.0	0.019	NaN	0.0	0.0014	0.0
4	Africa	2700	2.0	0.0	0.0	0.29	NaN	0.0	NaN	NaN	NaN	0.0014	0.0

3.0.e 5. Nettoyage de la date

La colonne `date` a été convertie au format `datetime` afin de permettre des analyses temporelles : évolution des cas, agrégation par mois, suivi de la progression de l'épidémie.

	date
0	2022-05-01
1	2022-05-02
2	2022-05-03
3	2022-05-04
4	2022-05-05

3.0.f 6. Suppression des agrégats non-pays

Les lignes correspondant aux continents ou aux agrégats globaux ont été supprimées afin de conserver uniquement les observations par pays.

```
array(['Andorra', 'Argentina', 'Aruba', 'Australia', 'Austria', 'Bahamas',
      'Bahrain', 'Barbados', 'Belgium', 'Benin', 'Bermuda', 'Bolivia',
      'Bosnia and Herzegovina', 'Brazil', 'Bulgaria', 'Cameroon',
      'Canada', 'Central African Republic', 'Chile', 'China'],
      dtype=object)
```

3.0.g 7. Suppression des colonnes redondantes

```
Colonnes          supprimées          :          ['new_cases_smoothed',
'new_deaths_smoothed', 'new_cases_per_million', 'total_cases_per_million',
'new_cases_smoothed_per_million', 'new_deaths_per_million',
'total_deaths_per_million', 'new_deaths_smoothed_per_million']
```

	country	date	total_cases	total_deaths	daily_new_cases	daily_new_deaths
370	Andorra	2022-07-25	2.0	0.0	2.0	0.0
371	Andorra	2022-07-26	3.0	0.0	1.0	0.0
372	Andorra	2022-07-27	3.0	0.0	0.0	0.0
373	Andorra	2022-07-28	3.0	0.0	0.0	0.0
374	Andorra	2022-07-29	3.0	0.0	0.0	0.0

3.0.h 8. Gestion des valeurs manquantes

Les valeurs manquantes des colonnes numériques principales ont été imputées par la médiane. Ce choix permet de limiter l'influence des valeurs extrêmes, fréquentes dans les données épidémiologiques où certains pays peuvent concentrer un nombre de cas beaucoup plus élevé que d'autres.

```
Valeurs manquantes après imputation :
total_deaths          0
```

```
daily_new_cases    0
daily_new_deaths    0
dtype: int64
```

3.0.i 9. tri, suppression des doublons et validation finale

	country	date	total_cases	total_deaths	daily_new_cases	daily_new_deaths
0	Andorra	2022-07-25	2.0	0.0	2.0	0.0
1	Andorra	2022-07-26	3.0	0.0	1.0	0.0
2	Andorra	2022-07-27	3.0	0.0	0.0	0.0
3	Andorra	2022-07-28	3.0	0.0	0.0	0.0
4	Andorra	2022-07-29	3.0	0.0	0.0	0.0

```
Dimensions finales : (30836, 6)
Doublons restants : 0
Valeurs manquantes restantes :
```

```
country    0
date       0
total_cases 0
total_deaths 0
daily_new_cases 0
daily_new_deaths 0
dtype: int64
```

3.0.j 10. Sauvegarde des données propres

Pour ce projet, le travail de data wrangling comprend :

- chargement du CSV brut ;
- audit initial du dataset : dimensions, types, valeurs manquantes et doublons ;
- conversion de la colonne date au format datetime ;
- suppression des agrégats globaux et continentaux ;
- renommage des colonnes principales ;
- traitement des valeurs manquantes par imputation ;
- suppression des colonnes redondantes ou peu utiles pour l'analyse ;
- vérification et suppression des doublons ;
- tri des données par pays et par date ;
- sauvegarde du dataset nettoyé pour l'analyse exploratoire.

```
Données nettoyées sauvegardées dans : ../data/processed/owid-monkeypox-  
data_clean.csv
```

4 Analyse Exploratoire des Données (EDA)

Dans cette section, nous analysons les relations statistiques fondamentales qui régissent votre domaine d'étude au sein du jeu de données.

4.1 Statistiques Descriptives

Le jeu de données nettoyé contient les variables principales liées au suivi du Mpox, notamment le pays, la date, le nombre total de cas, le nombre total de décès, les nouveaux cas quotidiens et les nouveaux décès quotidiens. Les premières observations montrent une structure temporelle cohérente, avec des valeurs numériques qui varient selon les pays.

Les variables cumulées comme `total_cases` et `total_deaths` permettent de suivre l'évolution globale de l'épidémie, tandis que les variables journalières `daily_new_cases` et `daily_new_deaths` mettent en évidence les fluctuations d'un jour à l'autre. On observe aussi que, dans certains pays, les décès restent nuls sur plusieurs périodes, ce qui traduit une faible mortalité observée dans ces données.

Dans l'ensemble, les variables nettoyées sont bien adaptées à une analyse descriptive, car elles permettent de comparer les pays, d'étudier l'évolution dans le temps et d'identifier les zones où la propagation est la plus marquée.

4.2 Ingénierie de Variables (Feature Engineering)

Dans notre cas, l'ingénierie de variables est restée assez limitée, car le dataset contient déjà les informations utiles pour suivre l'évolution du Mpox. Nous avons donc conservé les variables principales comme le pays, la date, les nouveaux cas, les nouveaux décès, les cas totaux et les décès totaux. Quand certaines valeurs de `total_deaths` étaient manquantes, nous les avons recalculées à partir des informations disponibles afin de garder une variable exploitable et cohérente.

L'intérêt de cette étape est de s'assurer que les données utilisées pour la suite du projet soient fiables et complètes. Cela permet aussi de garder une base propre pour l'analyse descriptive et la modélisation. En pratique, cela montre une démarche rigoureuse de préparation des données, ce qui est important dans un projet de data science. Cette étape a surtout servi à nettoyer, compléter et organiser les variables déjà présentes et enrichir la colonne `date` avec des variables temporelles simples : l'année, le mois, le mois au format année-mois et le jour de la semaine. Ces variables permettent de faciliter les regroupements temporels et l'analyse de l'évolution du Mpox dans le temps. C'est une approche adaptée à un rapport étudiant, parce qu'elle reste fidèle aux données réelles et au travail effectivement réalisé. ## Travaux Pratiques d'Exploration Visuelle (EDA)

5 📊 Jalon 1 : Analyse Exploratoire des Données (EDA) & Visualisation (Squelette Étudiant)

Ce notebook est dédié à la découverte de relations clés et à l'analyse visuelle de nos données. À partir du jeu de données propre généré précédemment, nous allons enrichir nos variables explicatives et appeler les fonctions de notre module de visualisation `src.utils_viz` pour générer des graphiques professionnels.

5.0.a 1. Importation des packages et configuration du style

🎨 Charte graphique 'light' initialisée avec succès.

	country	date	total_cases	total_deaths	daily_new_cases	daily_new_deaths
0	Andorra	2022-07-25	2.0	0.0	2.0	0.0
1	Andorra	2022-07-26	3.0	0.0	1.0	0.0
2	Andorra	2022-07-27	3.0	0.0	0.0	0.0
3	Andorra	2022-07-28	3.0	0.0	0.0	0.0
4	Andorra	2022-07-29	3.0	0.0	0.0	0.0

5.0.b 2. Ingénierie de variables temporelles


Appliquez la fonction `feature_engineering` de `src.data_clean` pour enrichir votre DataFrame en caractéristiques de temps classiques .

	country	date	total_cases	total_deaths	daily_new_cases	daily_new_deaths	year	month	year_month	dayofweek
0	An-dorra	2022-07-25	2.0	0.0	2.0	0.0	2022	7	2022-07	0
1	An-dorra	2022-07-26	3.0	0.0	1.0	0.0	2022	7	2022-07	1
2	An-dorra	2022-07-27	3.0	0.0	0.0	0.0	2022	7	2022-07	2
3	An-dorra	2022-07-28	3.0	0.0	0.0	0.0	2022	7	2022-07	3
4	An-dorra	2022-07-29	3.0	0.0	0.0	0.0	2022	7	2022-07	4

5.0.c 3. Visualisations Professionnelles

5.0.c.a A. Profils d'évolution et tendances

Appliquez la fonction `plot_generic_trends` de votre module `src.utils_viz` pour tracer l'évolution de la valeur par rapport au temps.



5.0.c.b B. Répartition mondiale des cas cumulés de mpox par pays

Cette carte permet de visualiser la répartition géographique des cas cumulés de mpox. Elle est pertinente car le dataset contient une dimension spatiale avec une variable pays. Contrairement à un simple tableau, la carte facilite l'identification rapide des zones les plus touchées et permet de comparer visuellement l'intensité de l'épidémie entre les pays.

Unable to display output for mime type(s): text/html

Unable to display output for mime type(s): text/html

5.0.c.c C. Carte animée de la propagation du mpox

Cette visualisation permet d'observer l'évolution géographique des cas de mpox au fil du temps. Comme le dataset contient une dimension temporelle (`year_month`) et une dimension géographique (`country`), une carte animée est pertinente pour analyser la propagation de l'épidémie entre les pays.

Unable to display output for mime type(s): text/html

5.0.d 4. Synthèse des observations clés

L'analyse exploratoire du dataset mpox met en évidence une forte dimension à la fois temporelle et géographique.

Le premier graphique, qui présente l'évolution des cas cumulés pour les cinq pays les plus touchés, montre que la progression de l'épidémie n'est pas identique selon les pays. Certains pays connaissent une croissance rapide du nombre de cas, tandis que d'autres présentent une évolution plus progressive. Cela confirme l'intérêt d'une analyse par pays plutôt qu'une analyse uniquement globale.

La carte animée de propagation apporte une lecture complémentaire en combinant la dimension spatiale et temporelle. Elle permet de visualiser l'évolution de l'épidémie dans le monde au fil des mois et d'identifier les zones où les cas apparaissent ou augmentent progressivement. L'agrégation mensuelle rend cette visualisation plus lisible que les données quotidiennes, souvent irrégulières.

Dans l'ensemble, les visualisations montrent que les variables les plus pertinentes pour analyser ce dataset sont `date`, `country`, `total_cases`, `daily_new_cases`, `total_deaths` et `daily_new_deaths`. Elles permettent de comprendre l'évolution de l'épidémie, d'identifier les pays les plus touchés et d'observer la diffusion géographique du mpox.

Cette première EDA confirme donc que le dataset est adapté à une analyse temporelle et géographique de l'épidémie. Elle fournit une base solide pour produire des indicateurs de suivi et approfondir l'analyse dans les étapes suivantes du projet.

6 Visualisation Multidimensionnelle (Insights)

Cette section présente les principaux résultats de l'exploration visuelle du dataset et met en évidence les tendances les plus importantes observées à travers les figures générées. ## Profils et Distributions Caractéristiques

```
#| label: fig-top5-countries
#| fig-cap: "Évolution des cas totaux dans les 5 pays les plus touchés."
#| echo: false

# Sélection des 5 pays les plus touchés
top_5_countries = (
    df_feat.groupby('country')['total_cases']
        .max()
        .sort_values(ascending=False)
        .head(5)
        .index
)

# Filtrage du dataset
df_top5 = df_feat[df_feat['country'].isin(top_5_countries)]

# Visualisation des tendances
fig1 = uv.plot_generic_trends(
```

```

df_top5,
x_col='date',
y_col='total_cases',
group_col='country'
)

plt.show()

```

Cette figure montre l'évolution du nombre total de cas dans cinq pays au cours du temps. On observe d'abord une forte montée des cas à partir de l'été 2022, avec des rythmes différents selon les pays, puis une stabilisation progressive vers le début de l'année 2023.

Un premier constat est que les États-Unis présentent le niveau de cas le plus élevé sur toute la période, avec une croissance rapide puis un plateau autour de 30 000 cas. Le Brésil arrive ensuite avec une progression plus lente mais continue, tandis que l'Espagne atteint également un niveau important avant de se stabiliser. La France et la Colombie affichent des volumes plus faibles, avec une montée plus tardive et une stabilisation autour de 4 000 cas.

Cette figure permet donc de voir que la propagation du Mpox n'a pas été uniforme selon les pays. Elle met en évidence des dynamiques très différentes, ce qui justifie une analyse par pays plutôt qu'une lecture globale unique. ## Répartition mondiale

```

#| label: fig-correlation
#| fig-cap: "Répartiton mondiale."
#| echo: false

import plotly.express as px

map_data = (
    df_feat.groupby("country", as_index=False)["total_cases"]
    .max()
    .sort_values(by="total_cases", ascending=False)
)

fig = px.choropleth(
    map_data,
    locations="country",
    locationmode="country names",
    color="total_cases",
    hover_name="country",
    color_continuous_scale="Reds",
    title="Répartition mondiale des cas cumulés de Mpox par pays"
)

```

```
fig.update_layout(
    title_x=0.5,
    geo=dict(showframe=False, showcoastlines=True)
)

fig.show()
```

Cette carte montre la répartition mondiale des cas cumulés de Mpox par pays. On voit clairement que les cas sont très concentrés dans quelques pays, surtout en Amérique du Nord et en Amérique du Sud, tandis que la majorité des autres pays affichent des niveaux plus faibles.

Un premier insight est que les États-Unis apparaissent comme le pays le plus touché sur cette carte, avec une couleur beaucoup plus foncée que les autres. On observe aussi un niveau élevé au Brésil, alors que les pays d'Europe, d'Afrique et d'Asie semblent globalement moins touchés dans ce jeu de données.

Cette visualisation est utile car elle permet de repérer rapidement les zones géographiques les plus concernées. Elle confirme que la propagation du Mpox n'est pas homogène à l'échelle mondiale et qu'une approche par pays reste nécessaire pour bien interpréter les données.

7 Modélisation et Apprentissage

7.1 Schéma Global du Pipeline de Données

Le pipeline complet intègre à la fois la branche analytique tabulaire (Machine Learning) et la branche d'analyse visuelle ou de signaux complexes (Deep Learning CNN) :

```
graph TD
    A[Données Brutes Multi-Sources CSV/API] -->|Formatage & Alignement| B(data_clean.clean_dates)
    C[Données Externes Complémentaires] -->|Imputation & Interpolation| D(data_clean.impute_missing_values)
    B & D -->|Gestion Outliers| E[Jeu de données Propre & Fusionné]
    E -->|Extraction Temporelle/Caractéristiques| F[Feature Engineering]
    F -->|Splits Temporels ou Stratifiés| G[Modèle Machine Learning Tabulaire]
    H[Flux Multimédias Réels Images/Signaux] -->|Prétraitement d'images/signaux| I[Réseau Convolutif CNN TensorFlow]
    G -->|Prédictions de la Problématique Métier| J[Livrables & Aide à la Décision]
    I -->|Détection de Motifs Complexes| J

    style E fill:#e0f2fe,stroke:#0284c7,stroke-width:2px
    style J fill:#f0fdf4,stroke:#16a34a,stroke-width:2px
    style G fill:#fef3c7,stroke:#d97706,stroke-width:2px
    style I fill:#fef3c7,stroke:#d97706,stroke-width:2px
```

7.2 Modélisation Tabulaire (Machine Learning)

À rédiger par les étudiants : Expliquez le choix de vos algorithmes d'apprentissage (supervisé ou non supervisé) et décrivez l'importance des variables explicatives.

[Détaillez votre modélisation ici]

7.2.a Travaux Pratiques de Modélisation Tabulaire

7.3 Modélisation Vision / Deep Learning (Analyse d'Images ou Signaux)

À rédiger par les étudiants : Expliquez l'intérêt de la brique de Deep Learning (images, signaux ou traitement de données structurées complexes) pour classifier ou enrichir vos prédictions. Détaillez l'architecture de votre réseau de neurones convolutif (CNN) conçu sous TensorFlow/Keras (conv, pooling, dense, dropout, activation) et commentez les courbes d'apprentissage obtenues.

[Détaillez votre architecture CNN et analyse ici]

7.3.a Travaux Pratiques de Vision par Ordinateur (CNN)

8 Évaluation Métrique et Validation

8.1 Stratégie de Validation

À rédiger par les étudiants : Expliquez pourquoi le découpage d'évaluation choisi (ex: validation temporelle, stratifiée ou par groupe) est adapté à la structure de vos données pour éviter les fuites de données.

[Rédiger la section de validation ici]

8.2 Résultats et Interprétation

À rédiger par les étudiants : Complétez le tableau d'évaluation ci-dessous en reportant vos résultats de modélisation.

Modèle	Métrique 1 (ex: MAE / Précision)	Métrique 2 (ex: RMSE / F1-Score)	R ² / Score (%)
Baseline (ex: Naïve / Moyenne)	[À compléter]	[À compléter]	[À compléter]
Modèle Choisi	[À compléter]	[À compléter]	[À compléter]

[Interpréter et comparer les métriques d'erreur calculées ici]

9 Data Storytelling et Communication

9.1 Recommandations Stratégiques / Métier

À rédiger par les étudiants : Formulez des recommandations stratégiques, opérationnelles et innovantes basées sur vos découvertes analytiques et prédictives pour guider les décideurs.

[Rédiger vos recommandations ici]

9.2 Limites et Perspectives

À rédiger par les étudiants : Identifiez honnêtement les biais ou limites de votre approche et proposez des pistes d'amélioration futures (ex: intégration de données externes réelles, modélisation plus poussée).

[Rédiger les limites et perspectives ici]

Ce document dynamique a été compilé en Quarto [2].

Bibliographie

Bibliography

- [1] W. McKinney, *Python for Data Analysis: Data Wrangling with Pandas, NumPy, and IPython*. O'Reilly Media, 2020.
- [2] Q. D. Team, “Quarto Dynamic Publishing System: Collaborative Scientific and Technical Publishing.” Accessed: May 18, 2026. [Online]. Available: <https://quarto.org/>