

Mon Projet Data Science

Projet Fil Rouge Data Science - Sujet Libre

Étudiante 1 : Monica RADIFERA RASAMOELI-
JAONA

Étudiant 2 : Hocine AKLI

2026-05-22

Table of contents

1	Introduction et Contexte Métier	2
1.1	Contexte du Projet	2
1.2	Objectif Analytique	3
2	Acquisition et Préparation des Données (Data Wrangling)	3
2.1	Audit de Qualité	3
3	 Jalon 1 : Data Wrangling & Nettoyage (Squelette Étudiant)	3
3.0.a	1. Importation des packages et chargement des données	4
3.0.b	2. Audit initial des données	4
3.0.c	3. Nettoyage des colonnes inutile	6
3.0.d	4. Renommage des colonnes	6
3.0.e	5. Nettoyage de la date	6
3.0.f	6. Suppression des agrégats non-pays	7
3.0.g	7. Suppression des colonnes redondantes	7
3.0.h	8. Gestion des valeurs manquantes	8
3.0.i	9. tri, suppression des doublons et validation finale	8
3.0.j	10. Sauvegarde des données propres	8
4	Analyse Exploratoire des Données (EDA)	9
4.1	Statistiques Descriptives	9
4.2	Ingénierie de Variables (Feature Engineering)	9
5	 Jalon 1 : Analyse Exploratoire des Données (EDA) & Visualisation (Squelette Étudiant) .	10
5.0.a	1. Importation des packages et configuration du style	10
5.0.b	2. Ingénierie de variables temporelles	10
5.0.c	3. Visualisations Professionnelles	11
5.0.d	4. Synthèse des observations clés	12
6	Modélisation et Apprentissage	12
6.1	Schéma Global du Pipeline de Données	12
6.2	Modélisation Tabulaire (Machine Learning)	13
6.2.a	Travaux Pratiques de Modélisation Tabulaire	14

7	🌸 Jalon 2 : Modélisation Prédicative & Apprentissage (Squelette Étudiant)	14
7.0.a	1. Préparation de l'environnement	14
7.0.b	2. Feature engineering	14
7.0.c	3. Définition des variables et split chronologique	15
7.0.d	4. Entraînement du modèle	15
7.0.e	5. Évaluation métrique et sélection du meilleur modèle	16
7.0.f	6. Visualisation des prédictions quotidiennes	16
7.1	Modélisation Vision / Deep Learning	17
8	Évaluation Métrique et Validation	17
8.1	Stratégie de Validation	17
8.2	Résultats et Interprétation	18
9	Data Storytelling et Communication	18
9.1	Recommandations Stratégiques / Métier	18
9.2	Limites et Perspectives	19
	Bibliographie	19
	Bibliography	19

1 Introduction et Contexte Métier



Figure 1: CI Compilation Pipeline

Ce projet analyse les données sur le Mpox (Monkeypox) pour mieux comprendre la propagation du virus. Face à l'émergence de cette maladie dans plusieurs pays, il est important de pouvoir suivre l'évolution des cas et identifier les zones à risque.

La problématique est de savoir comment prédire et anticiper la propagation du Mpox à partir de données réelles. Cela pose des questions scientifiques sur les tendances temporelles, les différences entre pays et les facteurs influençant la diffusion du virus.

L'objectif est d'offrir des insights utiles pour la prise de décision en santé publique : où surveiller davantage, quand anticiper un pic, et comment optimiser les moyens de prévention.

1.1 Contexte du Projet

Ce projet étudie la propagation du Mpox dans le but de détecter des tendances et des zones à risque. Le domaine d'étude est la santé publique, avec un focus sur l'épidémiologie et l'analyse de données temporelles.

Ce sujet est stratégique car le Mpox représente une menace sanitaire émergente, et sa surveillance permet de mieux préparer les systèmes de santé. Comprendre sa dynamique aide à prévenir de futures vagues de contamination.

L'analyse quantitative est indispensable car elle transforme des données brutes en indicateurs actionnables. Elle permet de mesurer objectivement l'évolution des cas, de comparer les pays et de fonder les décisions sur des faits plutôt que sur des intuitions.

1.2 Objectif Analytique

Les variables cibles principales sont la date, le pays, les new cases et new deaths (nouveaux cas et décès quotidiens), ainsi que les total cases et total deaths (cas et décès cumulés). L'objectif est d'analyser l'évolution de ces indicateurs dans le temps et d'identifier les pays les plus touchés par le Mpox.

Ce dataset est tabulaire avec des données épidémiologiques quotidiennes par pays sur une période d'un an. L'analyse se concentre sur les variables principales conservées après nettoyage

2 Acquisition et Préparation des Données (Data Wrangling)

Le succès de tout projet de Data Science repose sur la qualité de la préparation des données [1]. Cette section documente l'audit de qualité et les étapes de nettoyage appliquées à vos jeux de données bruts.

2.1 Audit de Qualité

Le fichier de données a été vérifié sur les aspects essentiels de qualité, notamment la structure des colonnes, la présence de valeurs manquantes et la présence éventuelle de doublons. L'audit a montré que certaines colonnes contenaient trop de cases vides, ce qui risquait de nuire à la fiabilité des analyses.

Nous avons donc choisi de supprimer ces colonnes afin de conserver uniquement les variables réellement exploitables. En parallèle, les doublons ont aussi été contrôlés pour éviter les répétitions dans le jeu de données et garantir une base plus propre.

Après ce tri, les données restantes ont pu être analysées sans difficulté majeure. Le dataset final est donc mieux adapté aux étapes d'exploration, de visualisation et de modélisation. ## Algorithme de Nettoyage Le traitement des données a commencé par un nettoyage des dates afin d'obtenir un format homogène et exploitable pour l'analyse temporelle. Nous avons ensuite supprimé les colonnes contenant trop de valeurs manquantes, car elles apportaient peu d'information et risquaient de fragiliser les analyses.

Comme le jeu de données contenait à la fois des informations au niveau des pays et des continents, nous avons conservé uniquement les données par pays afin d'avoir une analyse plus précise et plus cohérente.

Enfin, nous avons supprimé les colonnes jugées non utiles car redondantes, afin de simplifier le jeu de données et de garder uniquement les variables pertinentes pour l'analyse. Nous avons également traité les valeurs manquantes de la variable `total_deaths` à l'aide d'une imputation adaptée, afin de garantir la cohérence du dataset avant l'analyse. ## Travaux Pratiques de Wrangling

3 Jalon 1 : Data Wrangling & Nettoyage (Squelette Étudiant)

Ce notebook correspond à la première étape du **Jalon 1**. L'objectif est d'importer le jeu de données brut et d'effectuer un audit de sa qualité (données manquantes, anomalies physiques, formats de dates hétérogènes) et de le nettoyer à l'aide de votre package personnalisé `src.data_clean`.

3.0.a 1. Importation des packages et chargement des données

```
Libraries importées avec succès ! Prêt à démarrer le Wrangling.
```

	iso_code	date	total_cases	total_deaths	new_cases	new_deaths	new_cases_smoothed	new_deaths_smoothed	new_cases_per_million	total_cases_per_million	new_deaths_per_million	
0	AfricaOWID_20200501	2020-05-01	2.0	0.0	0.0	0.29	0.0	0.0	0.019	0.0	0.0	0.00140.0
1	AfricaOWID_20200502	2020-05-02	2.0	0.0	0.0	0.29	0.0	0.0	0.019	0.0	0.0	0.00140.0
2	AfricaOWID_20200503	2020-05-03	2.0	0.0	0.0	0.29	0.0	0.0	0.019	0.0	0.0	0.00140.0
3	AfricaOWID_20200504	2020-05-04	2.0	0.0	0.0	0.29	0.0	0.0	0.019	0.0	0.0	0.00140.0
4	AfricaOWID_20200505	2020-05-05	2.0	0.0	0.0	0.29	0.0	0.0	0.019	0.0	0.0	0.00140.0

3.0.b 2. Audit initial des données

Explorez le dataset brut pour évaluer sa structure : - Quelles sont les dimensions du dataset ? - Quels sont les types de données par colonne ? - Reste-t-il des valeurs nulles ? Quel est le taux de valeurs manquantes par variable ? - Y a-t-il des doublons ?

```
Dimensions : (33666, 15)
<class 'pandas.DataFrame'>
RangeIndex: 33666 entries, 0 to 33665
Data columns (total 15 columns):
#   Column                                Non-Null Count  Dtype
---  -
0   location                             33666 non-null  str
1   iso_code                             33666 non-null  str
2   date                                 33666 non-null  str
3   total_cases                          33666 non-null  float64
4   total_deaths                         33666 non-null  float64
5   new_cases                           33666 non-null  float64
6   new_deaths                          33666 non-null  float64
7   new_cases_smoothed                   33666 non-null  float64
8   new_deaths_smoothed                  33666 non-null  float64
9   new_cases_per_million                33666 non-null  float64
10  total_cases_per_million              33666 non-null  float64
11  new_cases_smoothed_per_million       33666 non-null  float64
12  new_deaths_per_million               33666 non-null  float64
13  total_deaths_per_million             33666 non-null  float64
14  new_deaths_smoothed_per_million      33666 non-null  float64
dtypes: float64(12), str(3)
memory usage: 3.9 MB
```

Valeurs manquantes par colonne :

location	0
iso_code	0
date	0
total_cases	0
total_deaths	0
new_cases	0
new_deaths	0
new_cases_smoothed	0
new_deaths_smoothed	0
new_cases_per_million	0
total_cases_per_million	0
new_cases_smoothed_per_million	0
new_deaths_per_million	0
total_deaths_per_million	0
new_deaths_smoothed_per_million	0
dtype:	int64

Taux de valeurs manquantes (%) :

location	0.0
iso_code	0.0
date	0.0
total_cases	0.0
total_deaths	0.0
new_cases	0.0
new_deaths	0.0
new_cases_smoothed	0.0
new_deaths_smoothed	0.0
new_cases_per_million	0.0
total_cases_per_million	0.0
new_cases_smoothed_per_million	0.0
new_deaths_per_million	0.0
total_deaths_per_million	0.0
new_deaths_smoothed_per_million	0.0
dtype:	float64

Nombre de doublons : 0

	total	total_deaths	new_cases	new_deaths	total_tests	new_tests	million	million	million	million	million	million	million
count	33666.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000
mean	1938.861870	8489.783728	0.122977	81166.012120	0.782519	725960.778460	0.000080	0.011196	0.000080				
std	8459.308549	9673.686005	1.216704	289502.088660	0.923803	0.910903	394290.002650	0.041820	0.000991				
min	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000
25%	4.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.680000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000
50%	21.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.878000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000
75%	257.000000	0.000000	0.000000	0.570000	0.000000	0.000000	0.936225	0.025000	0.000000	0.000000	0.000000	0.000000	0.000000
max	87376.000000	0.000000	0.000000	0.089140	0.000000	0.000000	0.836150	0.044300	0.268305	0.587380	0.031760		

3.0.c 3. Nettoyage des colonnes inutile

Supression de la colonne iso_code

	location	total	total_deaths	new_cases	new_deaths	total_cases	total_deaths	population	population_density	population_per_sqkm	population_per_sqmi	population_per_sqmi_million		
0	Africa	2022-03-27	700	2.0	0.0	0.0	0.29	0.0	0.0	0.019	0.0	0.0	0.0014	0.0
1	Africa	2022-03-27	702	2.0	0.0	0.0	0.29	0.0	0.0	0.019	0.0	0.0	0.0014	0.0
2	Africa	2022-03-27	703	2.0	0.0	0.0	0.29	0.0	0.0	0.019	0.0	0.0	0.0014	0.0
3	Africa	2022-03-27	704	2.0	0.0	0.0	0.29	0.0	0.0	0.019	0.0	0.0	0.0014	0.0
4	Africa	2022-03-27	705	2.0	0.0	0.0	0.29	0.0	0.0	0.019	0.0	0.0	0.0014	0.0

3.0.d 4. Renommage des colonnes

Renommage des colonnes cibles pour une analyse exploitable

	country	total	total	already	women	used	diseases	that	the	pharmaceutical	infectious	pathogens	million	
0	Africa	2022-03-27	700	2.0	0.0	0.0	0.29	0.0	0.0	0.019	0.0	0.0	0.0014	0.0
1	Africa	2022-03-27	700	2.0	0.0	0.0	0.29	0.0	0.0	0.019	0.0	0.0	0.0014	0.0
2	Africa	2022-03-27	700	2.0	0.0	0.0	0.29	0.0	0.0	0.019	0.0	0.0	0.0014	0.0
3	Africa	2022-03-27	700	2.0	0.0	0.0	0.29	0.0	0.0	0.019	0.0	0.0	0.0014	0.0
4	Africa	2022-03-27	700	2.0	0.0	0.0	0.29	0.0	0.0	0.019	0.0	0.0	0.0014	0.0

3.0.e 5. Nettoyage de la date

La colonne `date` a été convertie au format `datetime` afin de permettre des analyses temporelles : évolution des cas, agrégation par mois, suivi de la progression de l'épidémie.

0

	date
0	2022-05-01
1	2022-05-02
2	2022-05-03
3	2022-05-04
4	2022-05-05

3.0.f 6. Suppression des agrégats non-pays

Les lignes correspondant aux continents ou aux agrégats globaux ont été supprimées afin de conserver uniquement les observations par pays.

```
<StringArray>
[
    'Andorra',
    'Aruba',
    'Austria',
    'Bahrain',
    'Belgium',
    'Bermuda',
    'Bosnia and Herzegovina',
    'Bulgaria',
    'Canada',
    'Chile',
    'Argentina',
    'Australia',
    'Bahamas',
    'Barbados',
    'Benin',
    'Bolivia',
    'Brazil',
    'Cameroon',
    'Central African Republic',
    'China']
Length: 20, dtype: str
```

3.0.g 7. Suppression des colonnes redondantes

```
Colonnes      supprimées      :      ['new_cases_smoothed',
'new_deaths_smoothed', 'new_cases_per_million', 'total_cases_per_million',
'new_cases_smoothed_per_million', 'new_deaths_per_million',
'total_deaths_per_million', 'new_deaths_smoothed_per_million']
```

	country	date	total_cases	total_deaths	daily_new_cases	daily_new_deaths
370	Andorra	2022-07-25	2.0	0.0	2.0	0.0
371	Andorra	2022-07-26	3.0	0.0	1.0	0.0
372	Andorra	2022-07-27	3.0	0.0	0.0	0.0
373	Andorra	2022-07-28	3.0	0.0	0.0	0.0

	country	date	total_cases	total_deaths	daily_new_cases	daily_new_deaths
374	Andorra	2022-07-29	3.0	0.0	0.0	0.0

3.0.h 8. Gestion des valeurs manquantes

Les valeurs manquantes des colonnes numériques principales ont été imputées par la médiane. Ce choix permet de limiter l'influence des valeurs extrêmes, fréquentes dans les données épidémiologiques où certains pays peuvent concentrer un nombre de cas beaucoup plus élevé que d'autres.

```
Valeurs manquantes après imputation :
total_deaths      0
daily_new_cases    0
daily_new_deaths   0
dtype: int64
```

3.0.i 9. tri, suppression des doublons et validation finale

	country	date	total_cases	total_deaths	daily_new_cases	daily_new_deaths
0	Andorra	2022-07-25	2.0	0.0	2.0	0.0
1	Andorra	2022-07-26	3.0	0.0	1.0	0.0
2	Andorra	2022-07-27	3.0	0.0	0.0	0.0
3	Andorra	2022-07-28	3.0	0.0	0.0	0.0
4	Andorra	2022-07-29	3.0	0.0	0.0	0.0

```
Dimensions finales : (30836, 6)
Doublons restants : 0
Valeurs manquantes restantes :
```

```
country      0
date         0
total_cases   0
total_deaths  0
daily_new_cases  0
daily_new_deaths  0
dtype: int64
```

3.0.j 10. Sauvegarde des données propres

Pour ce projet, le travail de data wrangling comprend :

- chargement du CSV brut ;
- audit initial du dataset : dimensions, types, valeurs manquantes et doublons ;

- conversion de la colonne date au format datetime ;
- suppression des agrégats globaux et continentaux ;
- renommage des colonnes principales ;
- traitement des valeurs manquantes par imputation ;
- suppression des colonnes redondantes ou peu utiles pour l'analyse ;
- vérification et suppression des doublons ;
- tri des données par pays et par date ;
- sauvegarde du dataset nettoyé pour l'analyse exploratoire.

```
Données nettoyées sauvegardées dans : ../data/processed/owid-monkeypox-
data_clean.csv
```

4 Analyse Exploratoire des Données (EDA)

Dans cette section, nous analysons les relations statistiques fondamentales qui régissent votre domaine d'étude au sein du jeu de données.

4.1 Statistiques Descriptives

Le jeu de données nettoyé contient les variables principales liées au suivi du Mpox, notamment le pays, la date, le nombre total de cas, le nombre total de décès, les nouveaux cas quotidiens et les nouveaux décès quotidiens. Les premières observations montrent une structure temporelle cohérente, avec des valeurs numériques qui varient selon les pays.

Les variables cumulées comme `total_cases` et `total_deaths` permettent de suivre l'évolution globale de l'épidémie, tandis que les variables journalières `daily_new_cases` et `daily_new_deaths` mettent en évidence les fluctuations d'un jour à l'autre. On observe aussi que, dans certains pays, les décès restent nuls sur plusieurs périodes, ce qui traduit une faible mortalité observée dans ces données.

Dans l'ensemble, les variables nettoyées sont bien adaptées à une analyse descriptive, car elles permettent de comparer les pays, d'étudier l'évolution dans le temps et d'identifier les zones où la propagation est la plus marquée.

4.2 Ingénierie de Variables (Feature Engineering)

Dans notre cas, l'ingénierie de variables est restée assez limitée, car le dataset contient déjà les informations utiles pour suivre l'évolution du Mpox. Nous avons donc conservé les variables principales comme le pays, la date, les nouveaux cas, les nouveaux décès, les cas totaux et les décès totaux. Quand certaines valeurs de `total_deaths` étaient manquantes, nous les avons recalculées à partir des informations disponibles afin de garder une variable exploitable et cohérente.

L'intérêt de cette étape est de s'assurer que les données utilisées pour la suite du projet soient fiables et complètes. Cela permet aussi de garder une base propre pour l'analyse descriptive et la modélisation. En pratique, cela montre une démarche rigoureuse de préparation des données, ce qui est important dans un projet de data science. Cette étape a surtout servi à nettoyer, compléter

et organiser les variables déjà présentes et enrichir la colonne `date` avec des variables temporelles simples : l'année, le mois, le mois au format année-mois et le jour de la semaine. Ces variables permettent de faciliter les regroupements temporels et l'analyse de l'évolution du Mpox dans le temps. C'est une approche adaptée à un rapport étudiant, parce qu'elle reste fidèle aux données réelles et au travail effectivement réalisé. ## Travaux Pratiques d'Exploration Visuelle (EDA)

5 📊 Jalon 1 : Analyse Exploratoire des Données (EDA) & Visualisation (Squelette Étudiant)

Ce notebook est dédié à la découverte de relations clés et à l'analyse visuelle de nos données. À partir du jeu de données propre généré précédemment, nous allons enrichir nos variables explicatives et appeler les fonctions de notre module de visualisation `src.utils_viz` pour générer des graphiques professionnels.

5.0.a 1. Importation des packages et configuration du style

🎨 Charte graphique 'light' initialisée avec succès.

	country	date	total_cases	total_deaths	daily_new_cases	daily_new_deaths
0	Andorra	2022-07-25	2.0	0.0	2.0	0.0
1	Andorra	2022-07-26	3.0	0.0	1.0	0.0
2	Andorra	2022-07-27	3.0	0.0	0.0	0.0
3	Andorra	2022-07-28	3.0	0.0	0.0	0.0
4	Andorra	2022-07-29	3.0	0.0	0.0	0.0

5.0.b 2. Ingénierie de variables temporelles

Appliquez la fonction `feature_engineering` de `src.data_clean` pour enrichir votre DataFrame en caractéristiques de temps classiques .

	country	date	total_cases	total_deaths	daily_new_cases	daily_new_deaths	year	month	year_month	dayofweek
0	An-dorra	2022-07-25	2.0	0.0	2.0	0.0	2022	7	2022-07	0
1	An-dorra	2022-07-26	3.0	0.0	1.0	0.0	2022	7	2022-07	1
2	An-dorra	2022-07-27	3.0	0.0	0.0	0.0	2022	7	2022-07	2
3	An-dorra	2022-07-28	3.0	0.0	0.0	0.0	2022	7	2022-07	3

	country	date	total_cases	total_deaths	new_deaths	year	month	day	hour	minute	second	dayofweek
4	Andorra	2022-07-29	0.0	0.0	0.0	2022	7	2022-07	4			


5.0.c 3. Visualisations Professionnelles

5.0.c.a A. Profils d'évolution et tendances

Cette figure montre l'évolution du nombre total de cas dans cinq pays au cours du temps. On observe d'abord une forte montée des cas à partir de l'été 2022, avec des rythmes différents selon les pays, puis une stabilisation progressive vers le début de l'année 2023.

Un premier constat est que les États-Unis présentent le niveau de cas le plus élevé sur toute la période, avec une croissance rapide puis un plateau autour de 30 000 cas. Le Brésil arrive ensuite avec une progression plus lente mais continue, tandis que l'Espagne atteint également un niveau important avant de se stabiliser. La France et la Colombie affichent des volumes plus faibles, avec une montée plus tardive et une stabilisation autour de 4 000 cas.

Cette figure permet donc de voir que la propagation du Mpox n'a pas été uniforme selon les pays. Elle met en évidence des dynamiques très différentes, ce qui justifie une analyse par pays plutôt qu'une lecture globale unique.



5.0.c.b B. Répartition mondiale des cas cumulés de mpox par pays

Cette carte permet de visualiser la répartition géographique des cas cumulés de mpox. Elle est pertinente car le dataset contient une dimension spatiale avec une variable pays. Contrairement à un simple tableau, la carte facilite l'identification rapide des zones les plus touchées et permet de comparer visuellement l'intensité de l'épidémie entre les pays.

```
Unable to display output for mime type(s): text/html
```

```
Unable to display output for mime type(s): text/html
```

5.0.c.c C. Carte animée de la propagation du mpox

Cette visualisation permet d'observer l'évolution géographique des cas de mpox au fil du temps. Comme le dataset contient une dimension temporelle (`year_month`) et une dimension géographique (`country`), une carte animée est pertinente pour analyser la propagation de l'épidémie entre les pays.

```
Unable to display output for mime type(s): text/html
```

5.0.d 4. Synthèse des observations clés

L'analyse exploratoire du dataset mpox met en évidence une forte dimension à la fois temporelle et géographique.

Le premier graphique, qui présente l'évolution des cas cumulés pour les cinq pays les plus touchés, montre que la progression de l'épidémie n'est pas identique selon les pays. Certains pays connaissent une croissance rapide du nombre de cas, tandis que d'autres présentent une évolution plus progressive. Cela confirme l'intérêt d'une analyse par pays plutôt qu'une analyse uniquement globale.

La carte animée de propagation apporte une lecture complémentaire en combinant la dimension spatiale et temporelle. Elle permet de visualiser l'évolution de l'épidémie dans le monde au fil des mois et d'identifier les zones où les cas apparaissent ou augmentent progressivement. L'agrégation mensuelle rend cette visualisation plus lisible que les données quotidiennes, souvent irrégulières.

Dans l'ensemble, les visualisations montrent que les variables les plus pertinentes pour analyser ce dataset sont `date`, `country`, `total_cases`, `daily_new_cases`, `total_deaths` et `daily_new_deaths`. Elles permettent de comprendre l'évolution de l'épidémie, d'identifier les pays les plus touchés et d'observer la diffusion géographique du mpox.

Cette première EDA confirme donc que le dataset est adapté à une analyse temporelle et géographique de l'épidémie. Elle fournit une base solide pour produire des indicateurs de suivi et approfondir l'analyse dans les étapes suivantes du projet.

6 Modélisation et Apprentissage

6.1 Schéma Global du Pipeline de Données

Après l'étape de nettoyage et d'analyse exploratoire, nous avons mis en place une première approche de modélisation prédictive. L'objectif n'est pas de prédire médicalement l'apparition

de la maladie, mais plutôt d'estimer le nombre de nouveaux cas quotidiens de Mpox à partir de l'historique disponible dans le dataset.

Le projet repose sur des données tabulaires organisées par pays et par date. Le pipeline est donc centré sur une approche de Machine Learning supervisé, avec une cible numérique : `daily_new_cases`.

```
graph TD
    A[Données Brutes Multi-Sources CSV/API] -->|Formatage & Alignement| B(data_clean.clean_dates)
    C[Données Externes Complémentaires] -->|Imputation & Interpolation| D(data_clean.impute_missing_values)
    B & D -->|Gestion Outliers| E[Jeu de données Propre & Fusionné]
    E -->|Extraction Temporelle/Caractéristiques| F[Feature Engineering]
    F -->|Splits Temporels ou Stratifiés| G[Modèle Machine Learning Tabulaire]
    H[Flux Multimédias Réels Images/Signaux] -->|Prétraitement d'images/signaux| I[Réseau Convolutif CNN TensorFlow]
    G -->|Prédictions de la Problématique Métier| J[Livrables & Aide à la Décision]
    I -->|Détection de Motifs Complexes| J

    style E fill:#e0f2fe,stroke:#0284c7,stroke-width:2px
    style J fill:#f0fdf4,stroke:#16a34a,stroke-width:2px
    style G fill:#fef3c7,stroke:#d97706,stroke-width:2px
    style I fill:#fef3c7,stroke:#d97706,stroke-width:2px
```

6.2 Modélisation Tabulaire (Machine Learning)

La modélisation réalisée dans ce projet correspond à un problème de régression supervisée. La variable cible choisie est `daily_new_cases`, qui représente le nombre de nouveaux cas quotidiens de Mpox.

Ce choix est plus pertinent que la prédiction des cas cumulés (`total_cases`), car les cas cumulés augmentent mécaniquement au fil du temps. Prédire une variable cumulative risquerait donc de produire un résultat artificiellement bon, mais peu utile d'un point de vue analytique. À l'inverse, les nouveaux cas quotidiens sont plus difficiles à prédire, mais ils décrivent mieux la dynamique réelle de l'épidémie.

Pour éviter de mélanger des comportements très différents entre pays, la modélisation a été réalisée sur un seul pays : celui qui présente le plus grand nombre de nouveaux cas cumulés dans le dataset. Cette décision permet de travailler sur une série temporelle plus cohérente, avec une dynamique locale mieux identifiable.

Les variables explicatives utilisées sont principalement issues de l'historique des jours précédents. Nous avons créé plusieurs variables de retard, par exemple les nouveaux cas observés 1, 2, 3, 7, 14 et 21 jours auparavant. Nous avons également ajouté des moyennes mobiles et des maximums mobiles afin de lisser les variations quotidiennes et de mieux représenter les tendances récentes.

Plusieurs modèles ont été comparés :

une baseline naïve, qui prédit que les nouveaux cas du jour sont égaux à ceux de la veille ; un modèle Random Forest ; un modèle Extra Trees ; un modèle Gradient Boosting.

La baseline naïve est importante, car elle sert de point de comparaison. Un modèle de Machine Learning n'est intéressant que s'il apporte une amélioration par rapport à une règle simple.

Le modèle final est sélectionné automatiquement selon la MAE, c'est-à-dire l'erreur absolue moyenne. Cette métrique est adaptée à notre cas, car elle mesure directement l'écart moyen entre les nouveaux cas réels et les nouveaux cas prédits.

6.2.a Travaux Pratiques de Modélisation Tabulaire

7 Jalon 2 : Modélisation Prédictive & Apprentissage (Squelette Étudiant)

Dans ce notebook, l'objectif est de construire un pipeline de modélisation supervisée pour prédire le nombre de nouveaux cas quotidiens de Mpox (`daily_new_cases`) à partir des données historiques disponibles.

Le problème est traité comme une tâche de régression, car la variable cible est numérique. La modélisation est réalisée sur un seul pays afin d'éviter de mélanger des dynamiques épidémiques différentes entre plusieurs zones géographiques.

7.0.a 1. Préparation de l'environnement

```
 Charte graphique 'light' initialisée avec succès.  
Librairies de modélisation prêtes.
```

```
Pays sélectionné : United States
```

	country	date	total_cases	total_deaths	daily_new_cases	daily_new_deaths
0	United States	2022-06-03	19.0	0.0	19.0	0.0
1	United States	2022-06-04	21.0	0.0	2.0	0.0
2	United States	2022-06-05	25.0	0.0	4.0	0.0
3	United States	2022-06-06	25.0	0.0	0.0	0.0
4	United States	2022-06-07	25.0	0.0	0.0	0.0

7.0.b 2. Feature engineering

La variable cible choisie est `daily_new_cases`, c'est-à-dire le nombre de nouveaux cas quotidiens de Mpox. Ce choix est plus pertinent qu'une prédiction des cas cumulés, car les cas cumulés augmentent mécaniquement avec le temps.

Afin de respecter la causalité temporelle, seules des informations disponibles avant la date à prédire sont utilisées. Des variables de retard ont donc été créées : nouveaux cas des jours précédents, nouveaux décès retardés, cas cumulés retardés, moyennes mobiles et maximums mobiles.

	country	new_cases	new_deaths	new_cases_smoothed	new_deaths_smoothed	total_cases	total_deaths	total_recovered	active	in_hospital	in_icu	in_vmr	fatality_rate	recovery_rate	lag1	lag2	lag3	lag4	lag5	lag6	lag7	lag8	lag9	lag10	lag11	lag12	lag13	lag14
0	United States	2022-06-24	106.04	31.0	0.0	20226	4	29.0 ...	9.666667	10.000000	10.000000	10.000000	10.000000	10.000000	10.000000	10.000000	10.000000	10.000000	10.000000	10.000000	10.000000	10.000000	10.000000	10.000000	10.000000	10.000000	10.000000	
1	United States	2022-06-25	106.05	2.0	0.0	20226	5	31.0 ...	20.000000	12.734428	12.734428	12.734428	12.734428	12.734428	12.734428	12.734428	12.734428	12.734428	12.734428	12.734428	12.734428	12.734428	12.734428	12.734428	12.734428	12.734428	12.734428	
2	United States	2022-06-26	106.06	24.0	0.0	20226	6	2.0 ...	20.666667	10.734428	10.734428	10.734428	10.734428	10.734428	10.734428	10.734428	10.734428	10.734428	10.734428	10.734428	10.734428	10.734428	10.734428	10.734428	10.734428	10.734428	10.734428	
3	United States	2022-06-27	106.07	0.0	0.0	20226	0	24.0 ...	19.000000	12.285714	12.285714	12.285714	12.285714	12.285714	12.285714	12.285714	12.285714	12.285714	12.285714	12.285714	12.285714	12.285714	12.285714	12.285714	12.285714	12.285714	12.285714	
4	United States	2022-06-28	106.08	2.0	0.0	20226	1	0.0 ...	8.666667	12.285714	12.285714	12.285714	12.285714	12.285714	12.285714	12.285714	12.285714	12.285714	12.285714	12.285714	12.285714	12.285714	12.285714	12.285714	12.285714	12.285714	12.285714	

7.0.c 3. Définition des variables et split chronologique

Les variables explicatives sont composées de variables temporelles, de variables de retard et d'indicateurs mobiles calculés à partir des jours précédents.

Le découpage train/test est réalisé chronologiquement : les premières observations servent à l'entraînement et les observations les plus récentes sont réservées au test. Cette approche est indispensable pour éviter les fuites de données, car un split aléatoire pourrait utiliser des observations futures pour prédire le passé.

```
Taille Train : (256, 23)
Taille Test  : (64, 23)
Date min train : 2022-06-24 00:00:00
Date max train : 2023-03-06 00:00:00
Date min test  : 2023-03-07 00:00:00
Date max test  : 2023-05-09 00:00:00
```

7.0.d 4. Entraînement du modèle

Plusieurs modèles sont testés afin de ne pas dépendre d'un seul algorithme. Les modèles comparés sont :

- une baseline naïve, qui prédit le nombre de cas du jour à partir du nombre de cas de la veille ;
- un Random Forest Regressor ;
- un Extra Trees Regressor ;
- un HistGradientBoosting Regressor.

La cible est transformée avec `log1p` pendant l'entraînement afin de réduire l'impact des pics extrêmes. Les prédictions sont ensuite reconverties dans l'échelle d'origine avec `expm1`, puis arrondies car le nombre de cas est une variable de comptage.

	Modèle	MAE	RMSE	R ²
1	Random Forest	1.984375	5.789268	0.101735
2	Extra Trees	2.281250	5.939802	0.054414
3	Gradient Boosting	2.328125	6.135196	-0.008820
0	Baseline naïve	3.781250	9.022541	-1.181799

7.0.e 5. Évaluation métrique et sélection du meilleur modèle

Les performances sont évaluées à l'aide de trois métriques :

- **MAE** : erreur absolue moyenne, facile à interpréter car elle mesure l'écart moyen entre les valeurs réelles et prédites ;
- **RMSE** : erreur quadratique moyenne, qui pénalise davantage les grandes erreurs ;
- **R²** : part de variance expliquée par le modèle.

Le modèle retenu est celui qui obtient la plus faible MAE, car cette métrique est robuste et interprétable pour une variable de comptage comme le nombre de nouveaux cas quotidiens.


La baseline naïve sert de point de comparaison. Un modèle prédictif est réellement intéressant uniquement s'il améliore les performances par rapport à cette règle simple.

Meilleur modèle : Random Forest				
	Modèle	MAE	RMSE	R ²
1	Random Forest	1.984375	5.789268	0.101735
2	Extra Trees	2.281250	5.939802	0.054414
3	Gradient Boosting	2.328125	6.135196	-0.008820
0	Baseline naïve	3.781250	9.022541	-1.181799

7.0.f 6. Visualisation des prédictions quotidiennes

Le graphique ci-dessous compare les nouveaux cas quotidiens réels et prédits sur les 30 premiers jours de la période de test. Cette représentation permet d'observer visuellement les jours où le modèle surestime ou sous-estime les nouveaux cas.

La comparaison est réalisée sur un seul pays afin de conserver une lecture claire et cohérente de la dynamique temporelle.



Le graphique montre que le modèle parvient à produire des prédictions dans le même ordre de grandeur que les valeurs réelles. Cependant, certains pics restent sous-estimés. Ce comportement est attendu avec des données épidémiologiques quotidiennes, car les pics peuvent dépendre de facteurs externes absents du dataset, comme les retards de déclaration, les changements de politique de dépistage ou les variations de surveillance sanitaire.

Le modèle doit donc être interprété comme une première approche exploratoire de prédiction, et non comme un outil de prévision opérationnelle.

7.1 Modélisation Vision / Deep Learning

La partie Deep Learning de type CNN n'a pas été retenue dans ce projet, car le dataset utilisé est un jeu de données tabulaire épidémiologique. Il ne contient pas d'images, de signaux ou de données visuelles nécessitant l'utilisation d'un réseau de neurones convolutif.

Dans ce contexte, il est plus cohérent d'utiliser des modèles de régression tabulaire adaptés aux séries temporelles simples. Ce choix permet de rester aligné avec la nature réelle des données et d'éviter d'appliquer un modèle complexe qui ne serait pas justifié par le format du dataset.

8 Évaluation Métrique et Validation

8.1 Stratégie de Validation

La validation du modèle repose sur un découpage chronologique des données. Les premières observations de la série temporelle sont utilisées pour entraîner les modèles, tandis que les observations les plus récentes sont réservées au test.

Ce choix est essentiel dans un projet temporel. Un split aléatoire classique mélangerait des observations passées et futures, ce qui pourrait provoquer une fuite de données. Le modèle pourrait alors apprendre indirectement des informations issues du futur, ce qui donnerait une évaluation trop optimiste.

Le découpage chronologique simule une situation plus réaliste : on entraîne le modèle sur l'historique disponible, puis on teste sa capacité à prédire une période plus récente.

Nous avons également utilisé des variables de retard et des moyennes mobiles calculées uniquement à partir des valeurs passées. Cela permet de respecter la causalité temporelle : pour prédire une date donnée, le modèle n'utilise pas d'information provenant de cette date ou des jours suivants.

8.2 Résultats et Interprétation

Les modèles sont évalués à l'aide de trois métriques :

MAE : erreur absolue moyenne. Elle indique de combien de cas le modèle se trompe en moyenne ; RMSE : racine de l'erreur quadratique moyenne. Elle pénalise davantage les grosses erreurs ; R^2 : coefficient de détermination. Il mesure la part de variance expliquée par le modèle.

Modèle	Métrique 1 (MAE / Précision)	Métrique 2 (RMSE / F1-Score)	Métrique 3 (R^2 / Score (%))
Baseline	3.781250	9.022541	-1.181799
Random Forest	1.984375	5.789268	0.101735

La comparaison avec la baseline naïve permet d'évaluer si les modèles de Machine Learning apportent une réelle valeur ajoutée. Si le modèle choisi obtient une MAE plus faible que la baseline, cela signifie qu'il améliore la prédiction par rapport à une simple répétition de la valeur de la veille.

Le graphique de comparaison entre les valeurs réelles et les prédictions montre que le modèle arrive à produire des estimations dans le même ordre de grandeur que les observations réelles. Cependant, certains pics de nouveaux cas restent difficiles à anticiper. Cette limite est normale, car les données épidémiologiques quotidiennes peuvent être très irrégulières.

Les variations soudaines peuvent être liées à des facteurs qui ne sont pas présents dans le dataset, par exemple les retards de déclaration, les changements de politique de dépistage, les différences de surveillance sanitaire ou encore des événements locaux spécifiques.

Ainsi, le modèle doit être interprété comme une première approche exploratoire de prédiction. Il permet de tester la faisabilité d'une prévision à partir des données disponibles, mais il ne doit pas être considéré comme un outil opérationnel de prévision sanitaire.

9 Data Storytelling et Communication

9.1 Recommandations Stratégiques / Métier

L'analyse exploratoire et la modélisation montrent que la propagation du Mpox présente une forte dimension temporelle et géographique. Les cas ne sont pas répartis de manière uniforme entre les pays, et les dynamiques d'évolution peuvent fortement varier d'un territoire à l'autre.

Une première recommandation serait donc de mettre en place un suivi différencié par pays plutôt qu’une analyse uniquement mondiale. Les pays les plus touchés doivent faire l’objet d’un suivi plus détaillé, car ils concentrent une part importante des cas et présentent des dynamiques plus marquées.

Une deuxième recommandation concerne l’importance du suivi temporel. Les nouveaux cas quotidiens étant très variables, il est préférable de compléter l’analyse journalière par des indicateurs lissés, comme les moyennes mobiles sur 7 ou 14 jours. Cela permet d’éviter de surinterpréter des pics isolés et de mieux identifier les tendances de fond.

Enfin, la modélisation prédictive peut être utilisée comme un outil d’aide à la surveillance. Même si le modèle ne prédit pas parfaitement les pics, il permet d’identifier des tendances et de comparer les prédictions aux observations réelles. Un écart important entre la prédiction et la réalité pourrait signaler une variation inhabituelle nécessitant une analyse plus approfondie.

9.2 Limites et Perspectives

Le projet présente plusieurs limites importantes.

Tout d’abord, le dataset utilisé contient principalement des informations sur les cas, les décès, les pays et les dates. Il ne contient pas de variables externes comme la population, le taux de dépistage, les mesures sanitaires, la couverture vaccinale ou les différences de systèmes de surveillance. Ces facteurs peuvent pourtant influencer fortement le nombre de cas déclarés.

Ensuite, les données quotidiennes sont naturellement irrégulières. Certains pics peuvent être dus à des retards de déclaration ou à des corrections administratives, et non à une hausse réelle des contaminations. Cela rend la prédiction quotidienne particulièrement difficile.

Une autre limite concerne le choix de modéliser un seul pays. Cette approche améliore la cohérence temporelle, mais elle limite la généralisation du modèle à d’autres pays. Chaque territoire peut avoir une dynamique différente, ce qui nécessiterait idéalement une modélisation spécifique par pays ou un modèle global plus avancé intégrant mieux les différences géographiques.

Pour aller plus loin, plusieurs pistes d’amélioration sont possibles :

intégrer des variables externes, comme la population ou le nombre de tests réalisés ; comparer davantage de modèles spécialisés dans les séries temporelles ; réaliser une validation temporelle glissante au lieu d’un seul split train/test ;

Ce document dynamique a été compilé en Quarto [2].

Bibliographie

Bibliography

- [1] W. McKinney, *Python for Data Analysis: Data Wrangling with Pandas, NumPy, and IPython*. O'Reilly Media, 2020.

- [2] Q. D. Team, “Quarto Dynamic Publishing System: Collaborative Scientific and Technical Publishing.” Accessed: May 18, 2026. [Online]. Available: <https://quarto.org/>